

# Отчёт по выполненной работе

## Проект прогнозирования продаж Favorita

---

Итог: лучшей моделью стал обычный LightGBM на исходном raw train.csv. Лучшая валидация: NWRMSLE = 0.506773, WAPE = 0.435921, RMSLE = 0.508109.

### 1. Цель и постановка задачи

**Цель работы** — построить воспроизводимый пайплайн прогнозирования продаж для датасета Favorita, сравнить несколько классов моделей и выбрать практический финальный вариант для подготовки submission на Kaggle.

### 2. Выполненные этапы

- Подготовлены baseline-модели временных рядов: Naive, SeasonalNaive, AutoTheta, AutoETS.
- Реализован основной пайплайн на LightGBM с лаговыми и rolling-признаками.
- Проведён подбор гиперпараметров через Optuna и сравнение нескольких модификаций модели.
- Проверены альтернативные идеи: CatBoost, отдельные модели по дням недели, кластеризация рядов в латентном пространстве, заполнение активного периода нулями, LSTM.
- Проверены исходные данные на пропуски и разреженность рядов.
- Подготовлена финальная проектная структура с выделением конфигурации, загрузки данных, построения признаков, модели и рекурсивного прогнозирования.

### 3. Ключевые наблюдения по данным

- В исходном train.csv отсутствуют NaN в target unit\_sales, однако временные ряды сильно разрежены.
- В onpromotion найдено 21 657 651 пропусков (около 17.26% train).
- В oil присутствуют как пропуски значений, так и неполное покрытие по датам; для модели использовалось ffill/bfill.
- Почти 98.8% рядов имеют пропущенные даты внутри своего календарного диапазона.
- В test имеется 44 441 ряд, которые отсутствуют в train, поэтому финальный прогноз должен уметь работать с новыми unique\_id без собственной истории.

## 4. Сравнение основных экспериментов

Ниже приведены наиболее важные результаты. Для всех метрик меньше - лучше.

| Модель                          | NWRMSLE  | WAPE     | RMSLE    | Комментарий                               |
|---------------------------------|----------|----------|----------|-------------------------------------------|
| Naive                           | 0.726123 | 0.631268 | 0.726896 | Слабый baseline                           |
| SeasonalNaive                   | 0.708519 | 0.608011 | 0.710366 | Лучше Naive, но сильно уступает бустингам |
| AutoTheta                       | 0.583293 | 0.524187 | 0.585375 | Лучший baseline из классических           |
| AutoETS                         | 0.601907 | 0.542641 | 0.604834 | Хуже AutoTheta                            |
| CatBoost                        | 0.512519 | 0.449225 | 0.513929 | Лучше baseline, но хуже LightGBM          |
| LightGBM (лучший)               | 0.506773 | 0.435921 | 0.508109 | Лучший итоговый вариант                   |
| LightGBM + weekday split        | 0.509204 | 0.437192 | 0.510676 | Хуже обычного LightGBM                    |
| LightGBM + latent clustering    | 0.507482 | 0.437059 | 0.508845 | Очень близко, но всё же хуже              |
| Filled active period + raw eval | 0.585731 | 0.459104 | 0.588568 | Сильное ухудшение                         |

## 5. Основные выводы

- Обычный LightGBM оказался сильнее как baseline-моделей, так и более сложных альтернатив. P.S. По опыту моих предыдущих работ – LSTM мог дать хороший результат, я применял его для прогнозирования цен акций и продаж на WB, но тут довольно большой датасет и мне видеопамяти не хватает. Так же возможно класстеризация бы улучшила результат именно на тесте из-за большего кол-ва рядов – но проблема та же – видеопамять.
- Разбиение по дням недели не дало прироста качества, что говорит о достаточной гибкости одной общей модели.
- Кластеризация временных рядов в латентном пространстве оказалась исследовательски полезной, но практического улучшения качества не принесла.
- Гипотеза о заполнении отсутствующих дат внутри активного периода нулевыми продажами не подтвердилась: такой подход заметно ухудшил качество на raw eval.
- Итоговый пайплайн целесообразно строить именно вокруг raw LightGBM, а остальные ветки оставить как исследовательские эксперименты.